Một bộ phim. Ba góc nhìn.

Sự quan tâm của khán giả, khả năng tiếp cận và các bản chia sẻ trên BitTorrent liên hệ thế nào?

IMDb

Phim & sự quan tâm

TMDb / JustWatch

Phát hành & nơi xem

MagnetDB

Các bản chia sẻ được ghi nhận

Tích hợp và Phân tích dữ liệu lớn

19 slide

Ba nguồn dữ liệu và bước tiền xử lý

Mỗi nguồn trả lời một phần câu hỏi; tiền xử lý đưa ba nguồn về cùng một bộ phim.

01

IMDb

Hồ sơ phim: tên, năm, thể loại, điểm và lượt bình chọn. Lượt bình chọn là chỉ báo sự quan tâm.

02

TMDb / JustWatch

Ngày phát hành và nơi xem hợp pháp. Thông tin nơi xem trong TMDb do JustWatch cung cấp.

03

MagnetDB

Metadata các gói tệp chia sẻ qua BitTorrent. Đếm bản chia sẻ, không đếm người tải hoặc người xem.

TIỀN XỬ LÝ

1 Lọc phim

Chỉ phim lẻ; bỏ phim người lớn, tập phim bộ, sự kiện thể thao

2 Chuẩn hóa tên

Bỏ dấu, chữ thường, thêm tên theo từng nước (akas)

3 Ghép thực thể

Tên + năm từ tên torrent ↔ IMDb; TMDb nối qua imdb_id

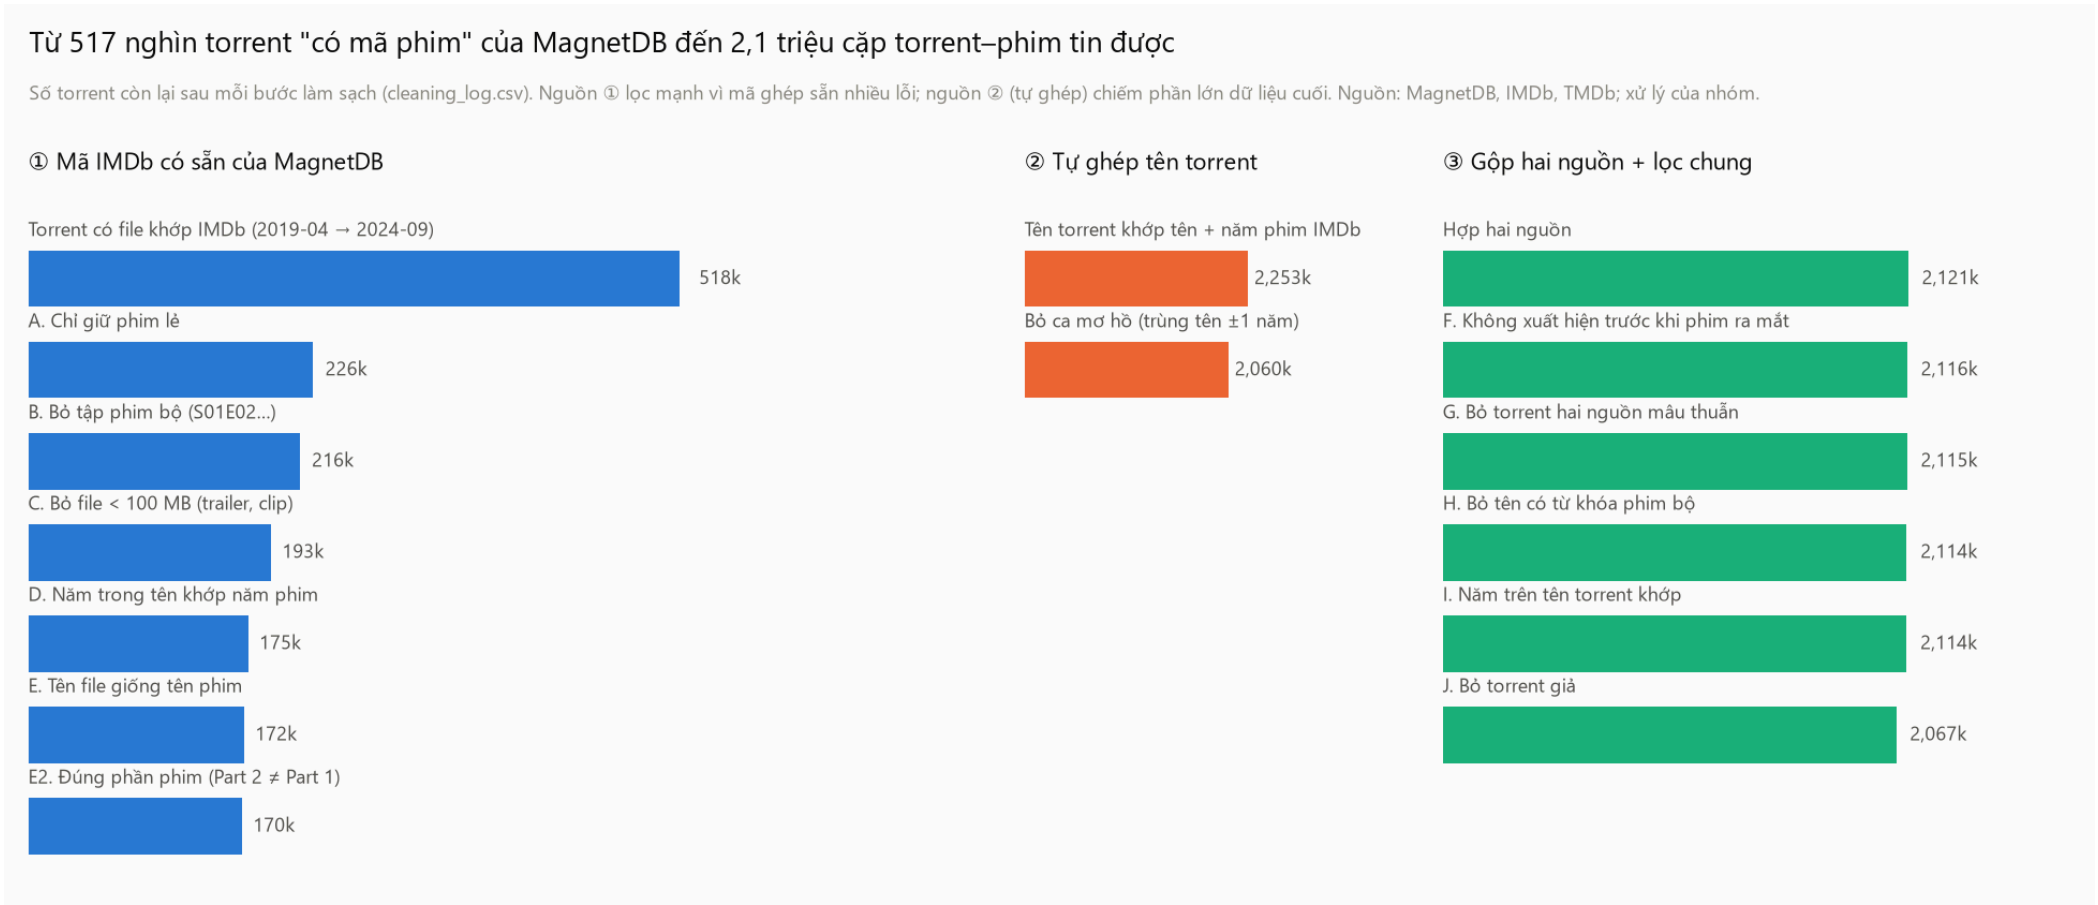
4 Làm sạch

Bỏ tệp < 100 MB, năm lệch, ca trùng tên, torrent giả

Dữ liệu còn lại sau từng bước làm sạch

5 Cửa sổ thời gian

Chỉ giữ giai đoạn thu thập ổn định 04/2021 – 09/2024



Chuẩn hóa dữ liệu và tạo chỉ mục tên phim

Bước 01–03, 10 · Trích phần cần dùng, giữ định danh và đưa tên phim về cùng một dạng.

MAGNETDB · SQLITE 117 GB

Lấy metadata cần phân tích

- Tên torrent, tên file, dung lượng và thời điểm phát hiện.
- Ghép theo `torrent_id`, chuyển phần trích xuất sang Parquet.
- Sửa tên lỗi mã hóa; giữ dữ liệu gốc để đối chiếu.

Đầu ra: `matched_files`, `magnetdb_matched_slice`, `mdb_*`

IMDB · BASICS + RATINGS + AKAS

Một phim có nhiều tên để tra

- Giữ `titleType = movie`; nối điểm và bình chọn bằng `tconst`.
- Thêm tên gốc và tên ở các nước từ `title.akas`.
- Bỏ dấu, viết thường và bỏ ký tự đặc biệt.

758.524 phim · **1.875.336** tên trong chỉ mục.

VÍ DỤ TÊN THAY THẾ TRONG NOTEBOOK

El gran Lebowski → `el gran lebowski` → **The Big Lebowski · 1998** tt0118715

Tên thay thế vẫn dẫn về cùng một mã IMDb; chưa cần so khớp gần đúng.

Nguồn: notebook 00_quy_trinh_xu_ly · số liệu và ví dụ từ kết quả đã lưu.

Ghép chính xác tên chuẩn hóa + năm; bỏ ca mơ hồ

Bước 04, 08 · Nhánh ghép tên chính dùng chỉ mục IMDb; một pipeline khác được dùng để đối chiếu.

01 · Làm sạch tên

Bỏ tiền tố trang, đuôi file; loại dấu hiệu phim bộ.

02 · Tách tên + năm

Lấy tên trước năm; không nhầm 1080p với năm phim.

03 · Tra chính xác

Tên chuẩn hóa trùng chỉ mục; năm lệch tối đa ±1.

04 · Bỏ mơ hồ

Nhiều phim trùng tên hoặc tên quá chung chung.

VÍ DỤ GHÉP THẬT

`Parasite.2019.PLSUBBED.480p.WEB-DL.XViD.AC3-LLA.avi`

parasite + 2019 → **Parasite (2019)**

2.253.337
dòng ghép ban đầu

193.739
ca mơ hồ bị bỏ

122.990
phim sau loại mơ hồ

Đối chiếu độc lập: guessit + rapidfuzz trên 20.000 tên file, so với nhãn MagnetDB: precision **87,9%**, recall **63,2%**. Đây là phép đối chiếu tham chiếu, không phải tỷ lệ đúng của toàn bộ pipeline chính.

Nguồn: notebook 00_quy_trinh_xu_ly · số liệu và ví dụ từ kết quả đã lưu.

Bổ sung TMDb bằng mã IMDb, rồi tách thành 3 bảng

Bước 05–07 · Hợp danh sách phim → tìm TMDb theo imdb_id → lưu đệm JSON → xuất Parquet.

`IMDb · tconst` → `TMDb · /find` → JSON lưu đệm → **3 bảng theo mức chi tiết**

1 DÒNG / PHIM

`tmdb_movies`

Ngân sách, doanh thu, ngôn ngữ và các mốc phát hành tóm tắt.

Top Gun: Maverick

tt1745960

Ngân sách: 170 triệu USD

Doanh thu: khoảng 1,49 tỷ USD

NHIỀU DÒNG / PHIM

`tmdb_release_dates`

Ngày phát hành theo quốc gia và hình thức: Premiere, rạp, Digital, đĩa, TV.

Cùng phim · thị trường Mỹ

`country = US · type = 1`

Premiere: 04/05/2022

Mỗi hình thức có mốc riêng.

PHIM × NƯỚC × HÌNH THỨC × DỊCH VỤ

`tmdb_watch_providers`

Bộ lọc A–J xử lý những lỗi nào?

Cùng phim · nơi xem tại Mỹ
Bước 09 · Kiểm tra nội dung, danh tính phim, sự nhất quán giữa nguồn và các mốc thời gian.
Netflix và các dịch vụ khác.

Năm nhóm kiểm tra

A–C	Chỉ phim lẻ; bỏ tập phim bộ và file dưới 100 MB.
D–E2	Kiểm tra năm, độ giống tên và đúng phần phim.
F	Bỏ torrent sớm hơn lần ra mắt đầu tiên trên 60 ngày.
G–I	Bỏ ghép mâu thuẫn, dấu hiệu phim bộ và năm lệch.
J	Gắn cờ bản WEB/BluRay có thời điểm khó hợp lý; loại cờ này khi phân tích.

Ba ví dụ bị loại trong notebook

B · Nhầm phim bộ thành phim lẻ

…`S03E01`… bị gán vào *A Series of Unfortunate Events* (2004).

D · Tên đúng, năm sai

Independence Day · tên file **2016** nhưng phim được gán là **1996**.

J · Tự xưng BluRay trước ngày ra mắt

Ant-Man and the Wasp: Quantumania
Phát hiện **18/12/2022** · ra rạp **15/02/2023**.

Có thể truy vết: số lượng còn lại được ghi trong `cleaning_log.csv`; bảng torrent giữ các cờ như `is_pack`, `quality_tier` và `implausible`.

Nguồn: notebook 00_quy_trinh_xu_ly · số liệu và ví dụ từ kết quả đã lưu.

Chốt hai bảng sạch, phân biệt đơn vị và thời gian

Đầu ra bước 09 · Một bảng theo cặp torrent–phim và một bảng tổng hợp theo phim.

1 DÒNG = 1 CẶP TORRENT–PHIM

torrents_clean

Mã torrent + IMDb; nguồn ghép, chất lượng, cờ gói nhiều phim, cờ bất thường và ngày phát hiện UTC.

Số cặp có thể lớn hơn số torrent vì một gói chứa nhiều phim.

1 DÒNG = 1 PHIM

movie_analysis

Hồ sơ IMDb + TMDb và thống kê torrent theo phim trong cửa sổ quan sát.

Đếm torrent riêng biệt theo phim trước khi tính chỉ số so sánh.

2.078.927
cặp sạch · toàn phạm vi

2.066.598
torrent riêng biệt · toàn phạm vi

126.081
phim có cặp sạch · toàn phạm vi

923.998
cặp trong cửa sổ quan sát

Cửa sổ thống kê chính · UTC `01/04/2021 ≤ ngày phát hiện < 29/09/2024`

Chọn giai đoạn thu thập ổn định hơn; vẫn có gián đoạn.

IMDb · năm phim

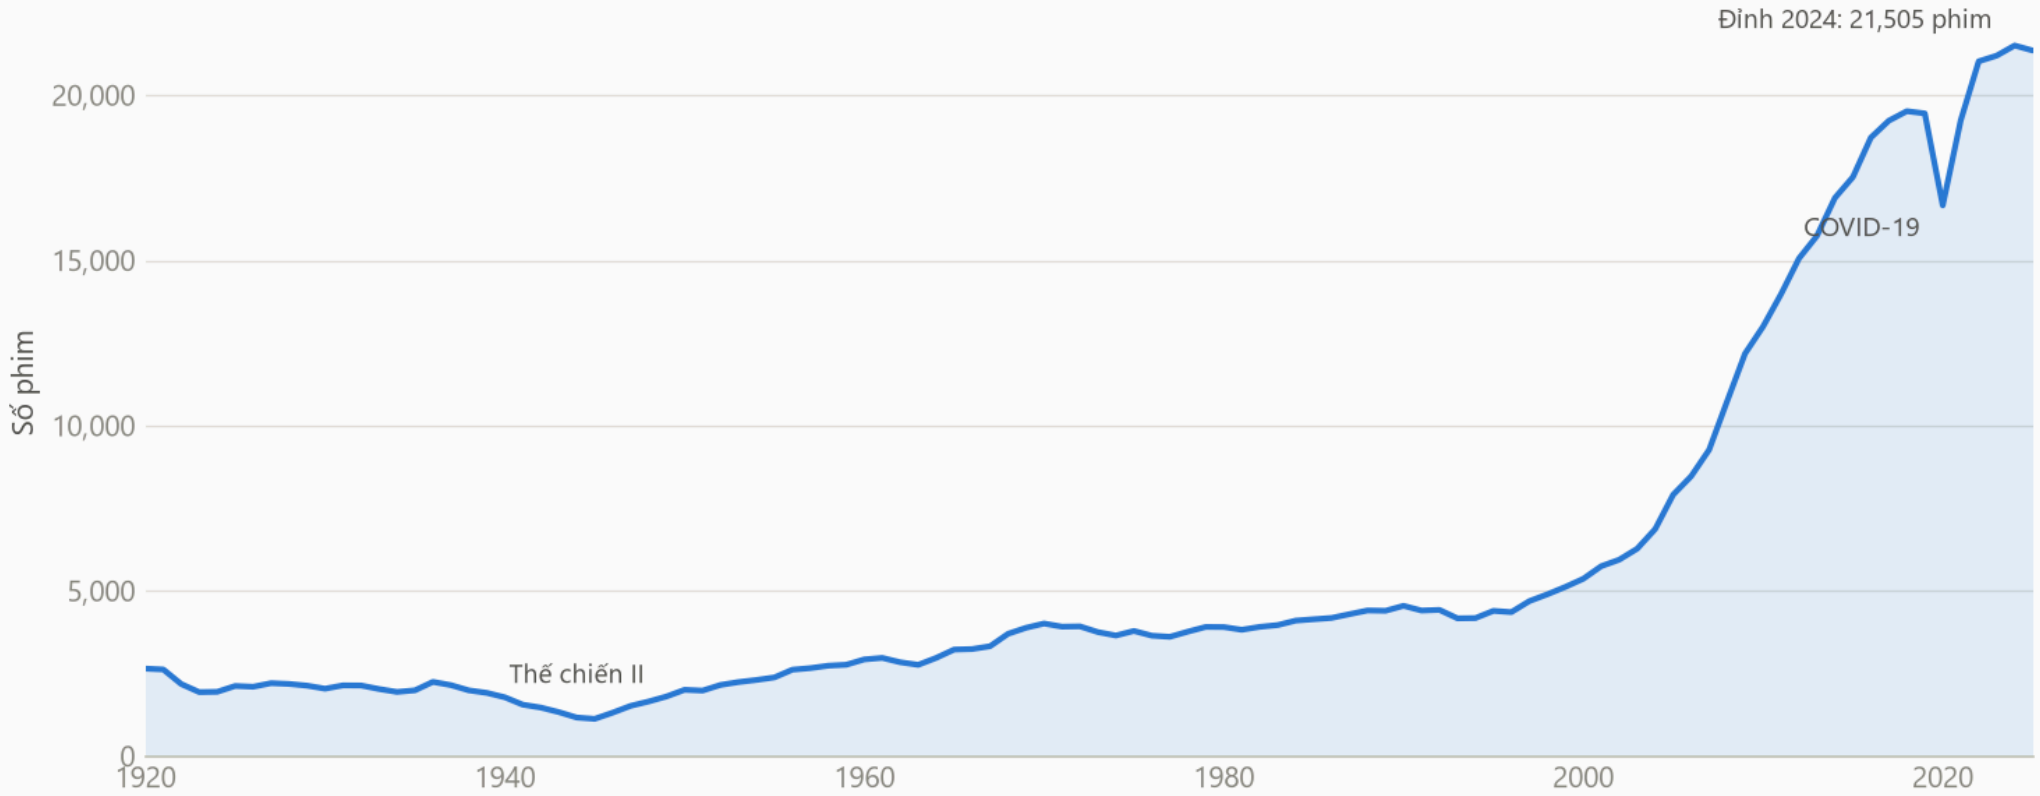
TMDb · ngày phát hành theo nước/loại

Kho phim thay đổi thế nào theo thời gian?

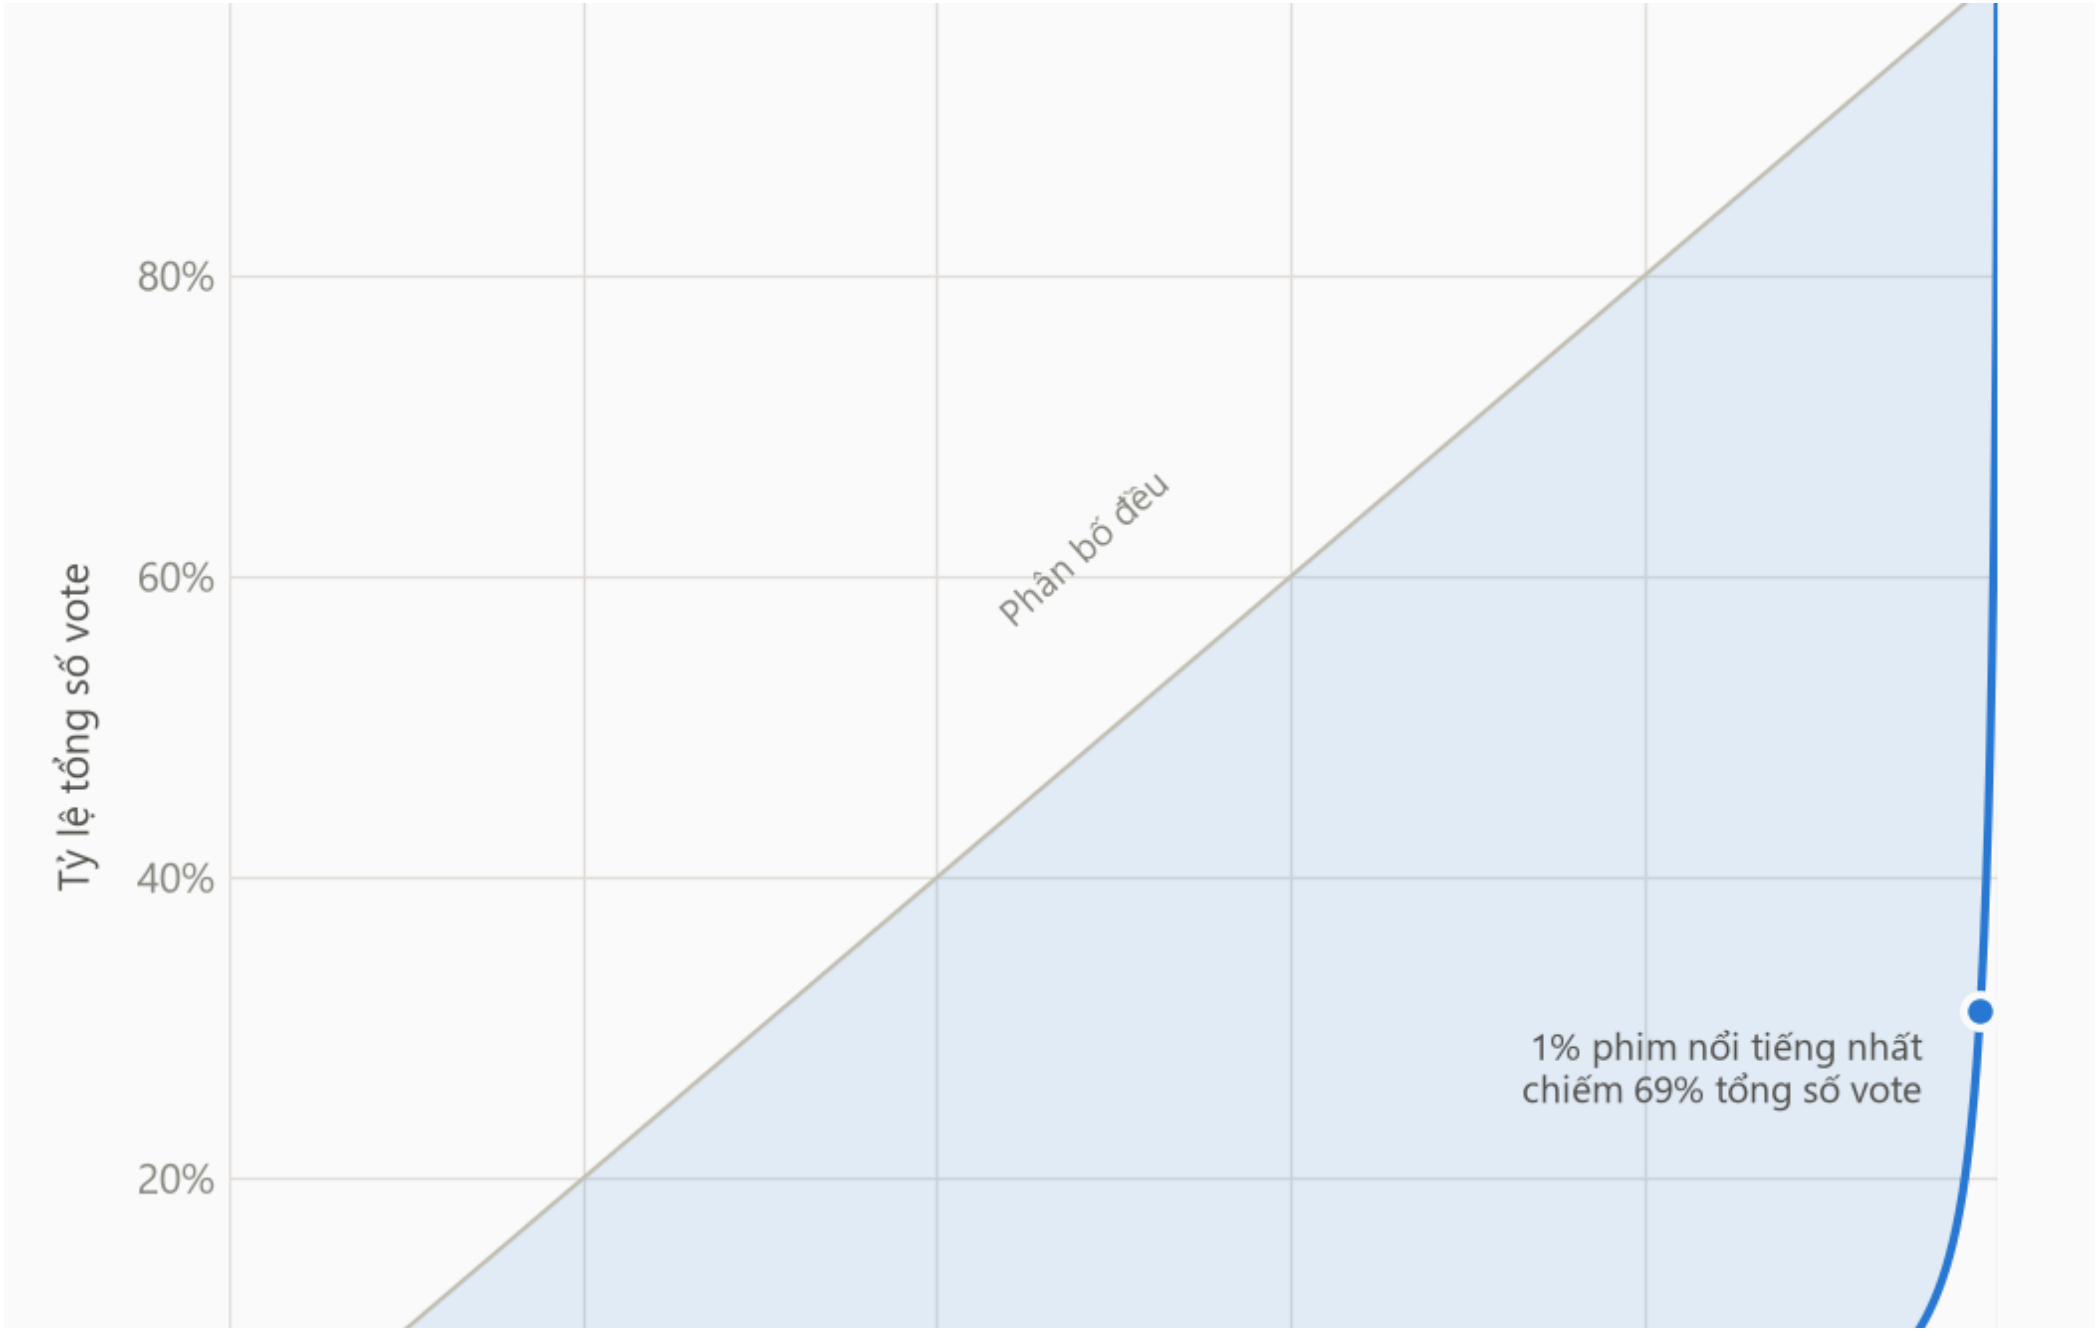
Các số đếm sách loại `implausible`. Ngày phát hiện không phải ngày tạo torrent, điểm và lượt xem là ảnh chụp năm 2026.

Số phim điện ảnh sản xuất mỗi năm tăng gấp ~8 lần trong 100 năm

Phim có trên IMDb (không tính phim người lớn), theo năm sản xuất. Năm gần nhất có thể chưa đủ do IMDb cập nhật trễ. Nguồn: IMDb Non-Commercial Datasets (2026).



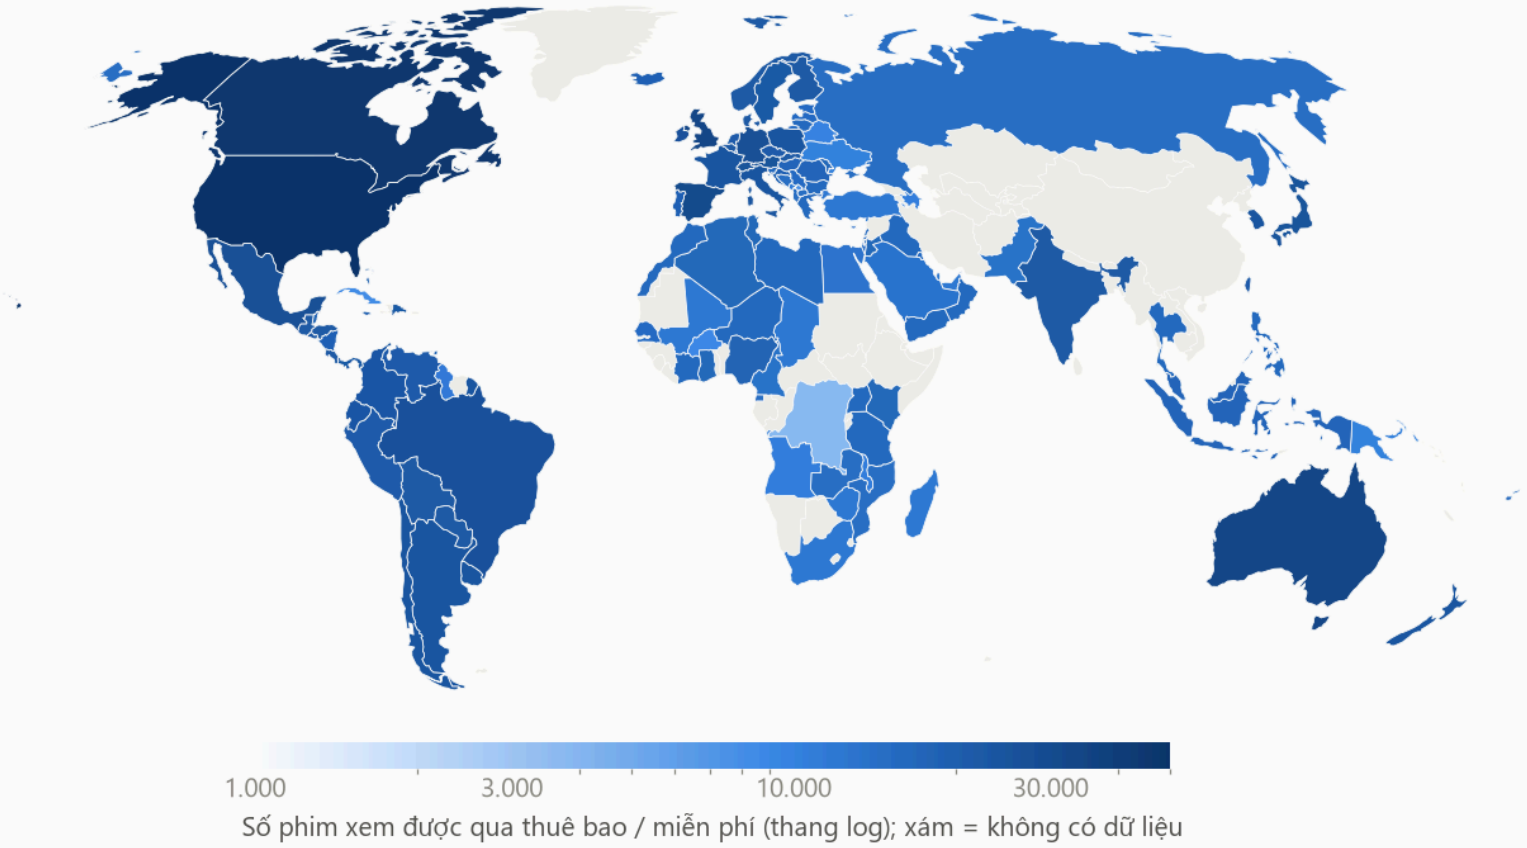
Sự chú ý tập trung vào một nhóm phim nhỏ



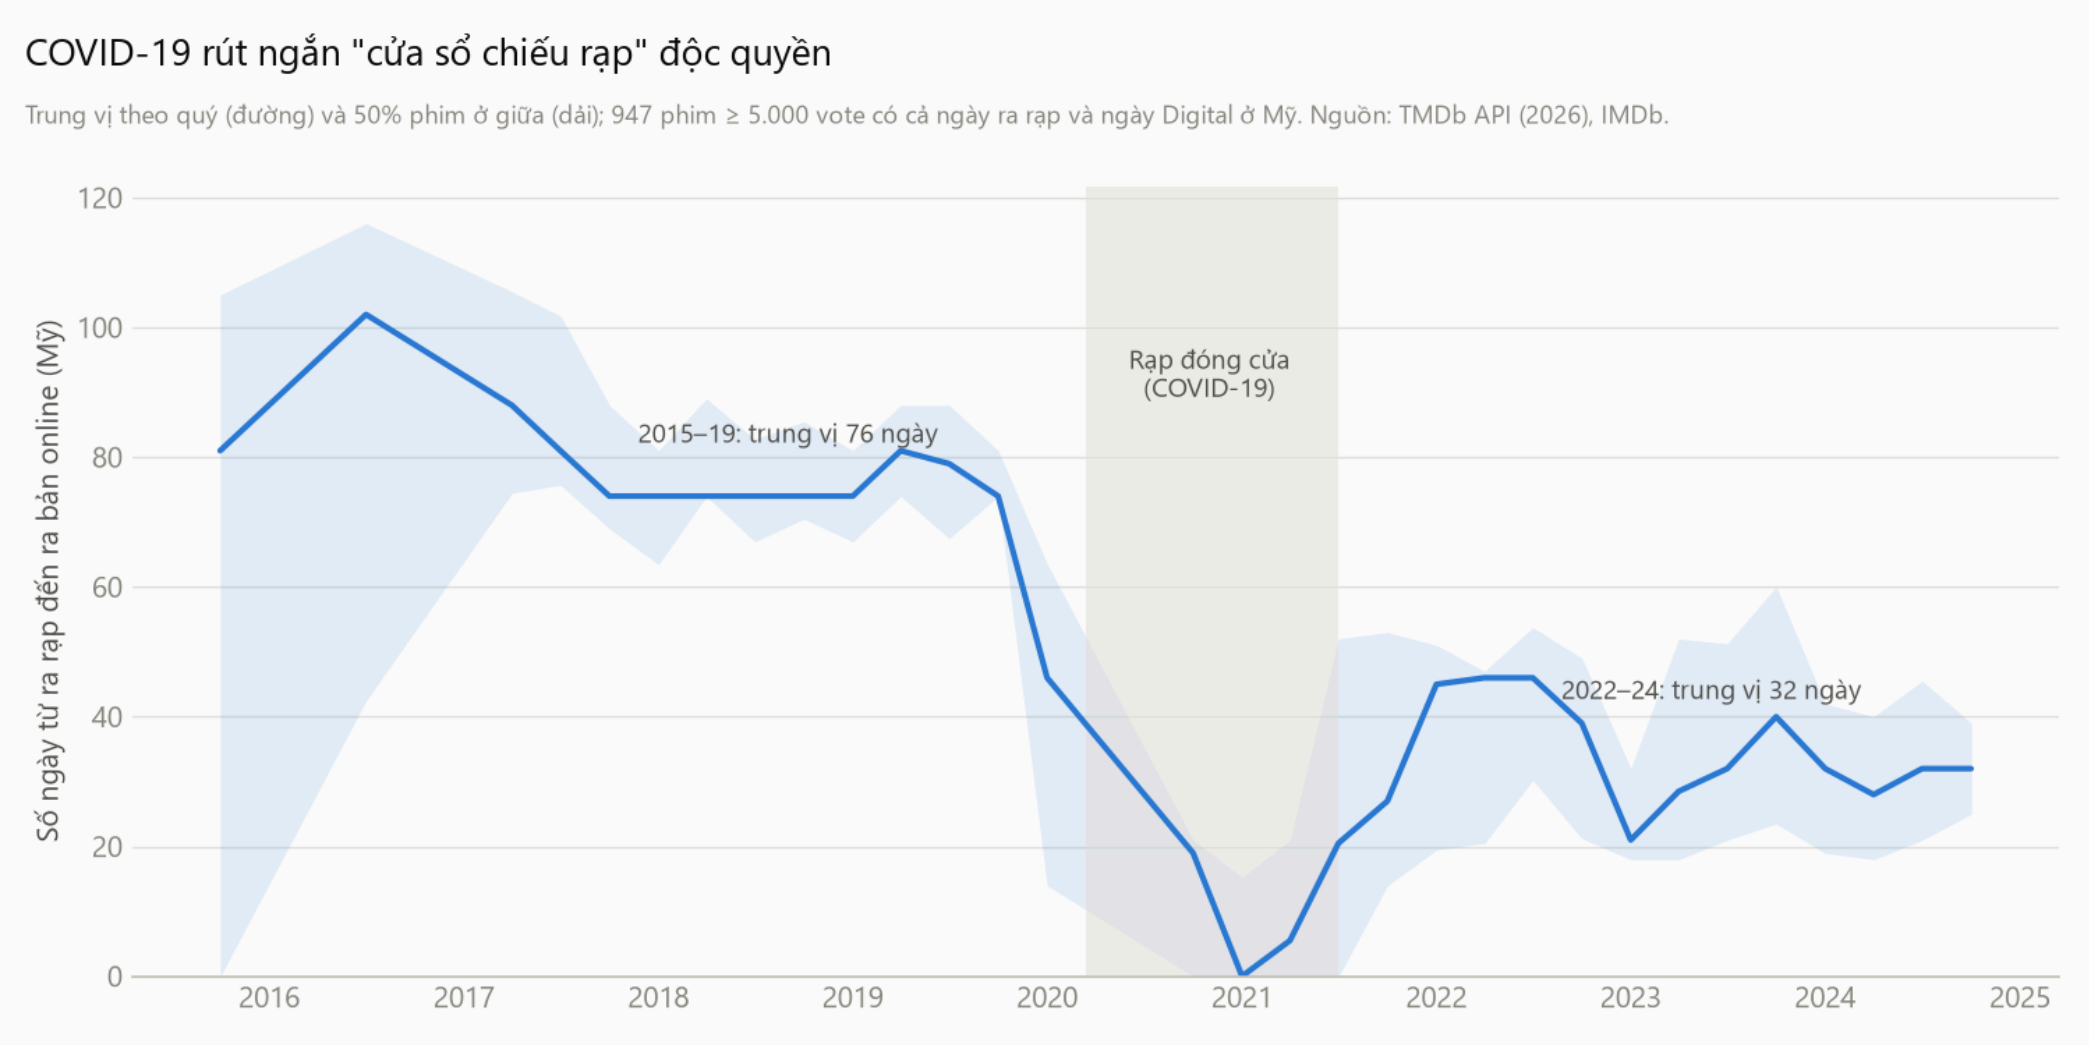
Nơi xem phim khác nhau giữa các quốc gia

Kho phim streaming hợp pháp lớn nhất ở Bắc Mỹ, Tây Âu và Úc

Số phim (trong 103,769 phim của dự án) có trên ít nhất một dịch vụ thuê bao/miễn phí ở mỗi nước. Cao nhất: Mỹ 57,445, Canada 45,818, Anh 34,110. Xám: JustWatch không theo dõi (vd. Trung Quốc). Nguồn: TMDb API (2026), dữ liệu streaming do JustWatch cung cấp.



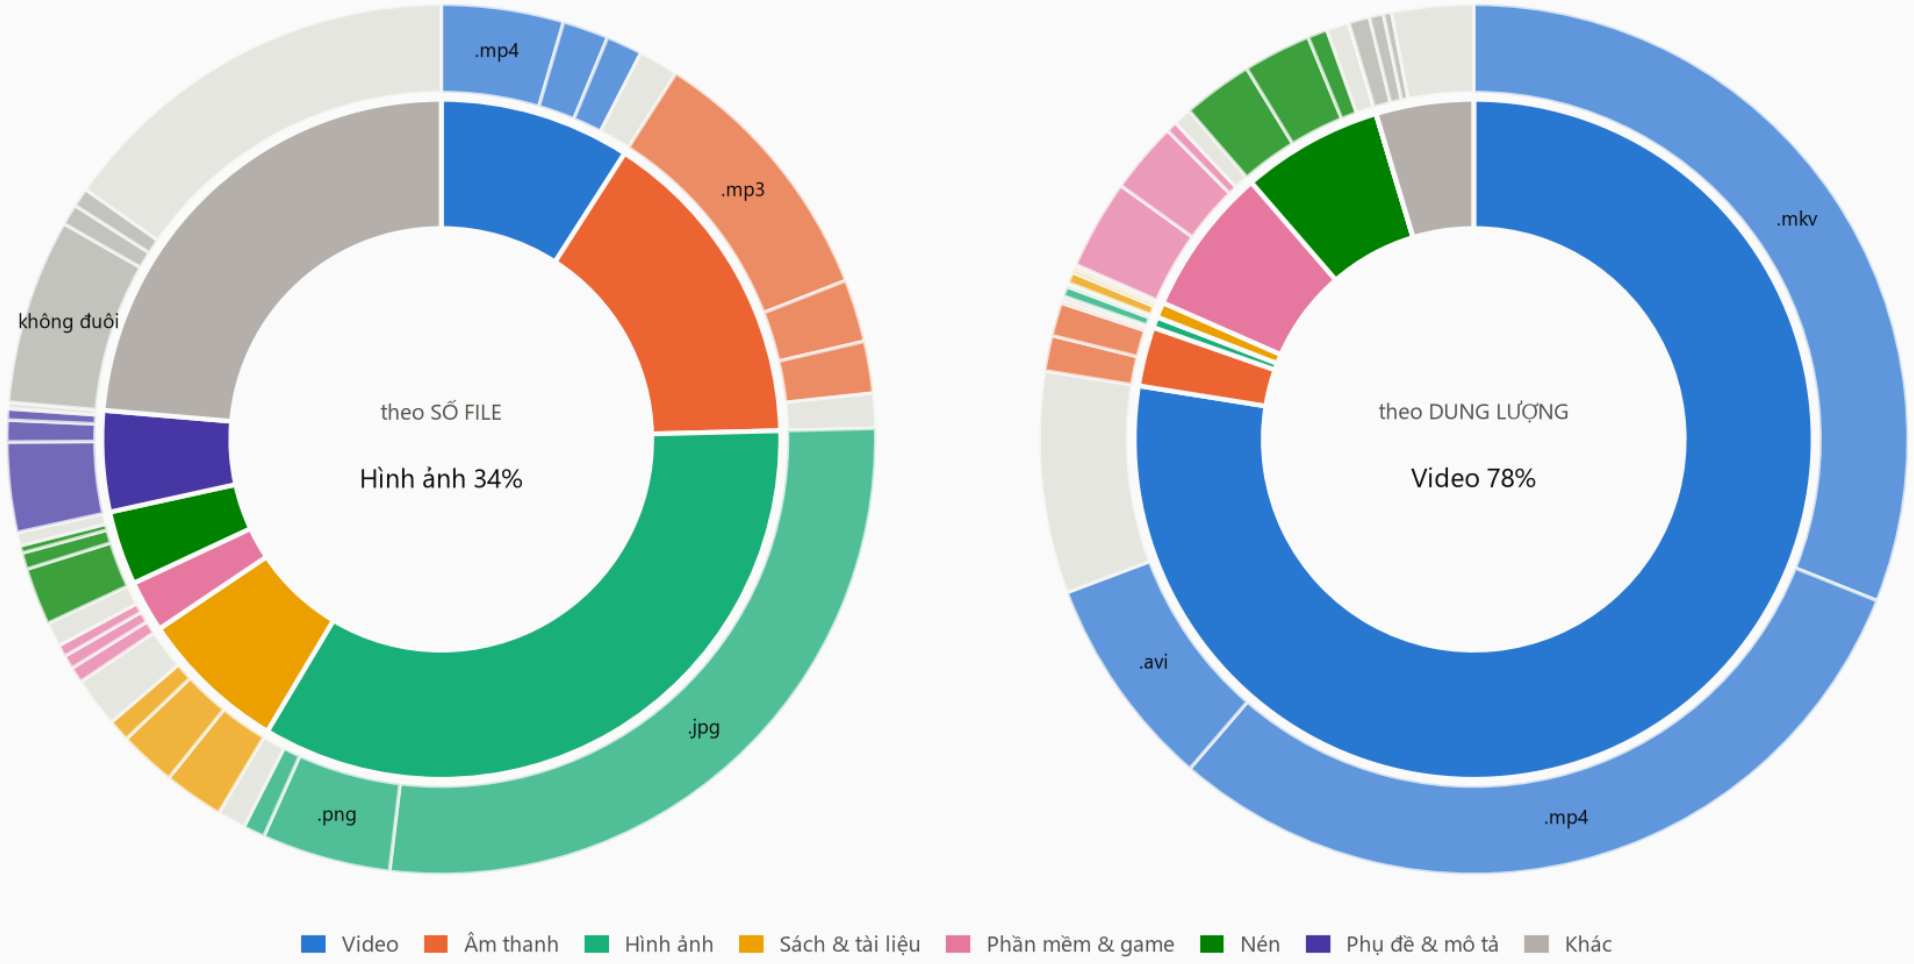
Từ chiếu rạp đến phát hành số mất bao lâu?



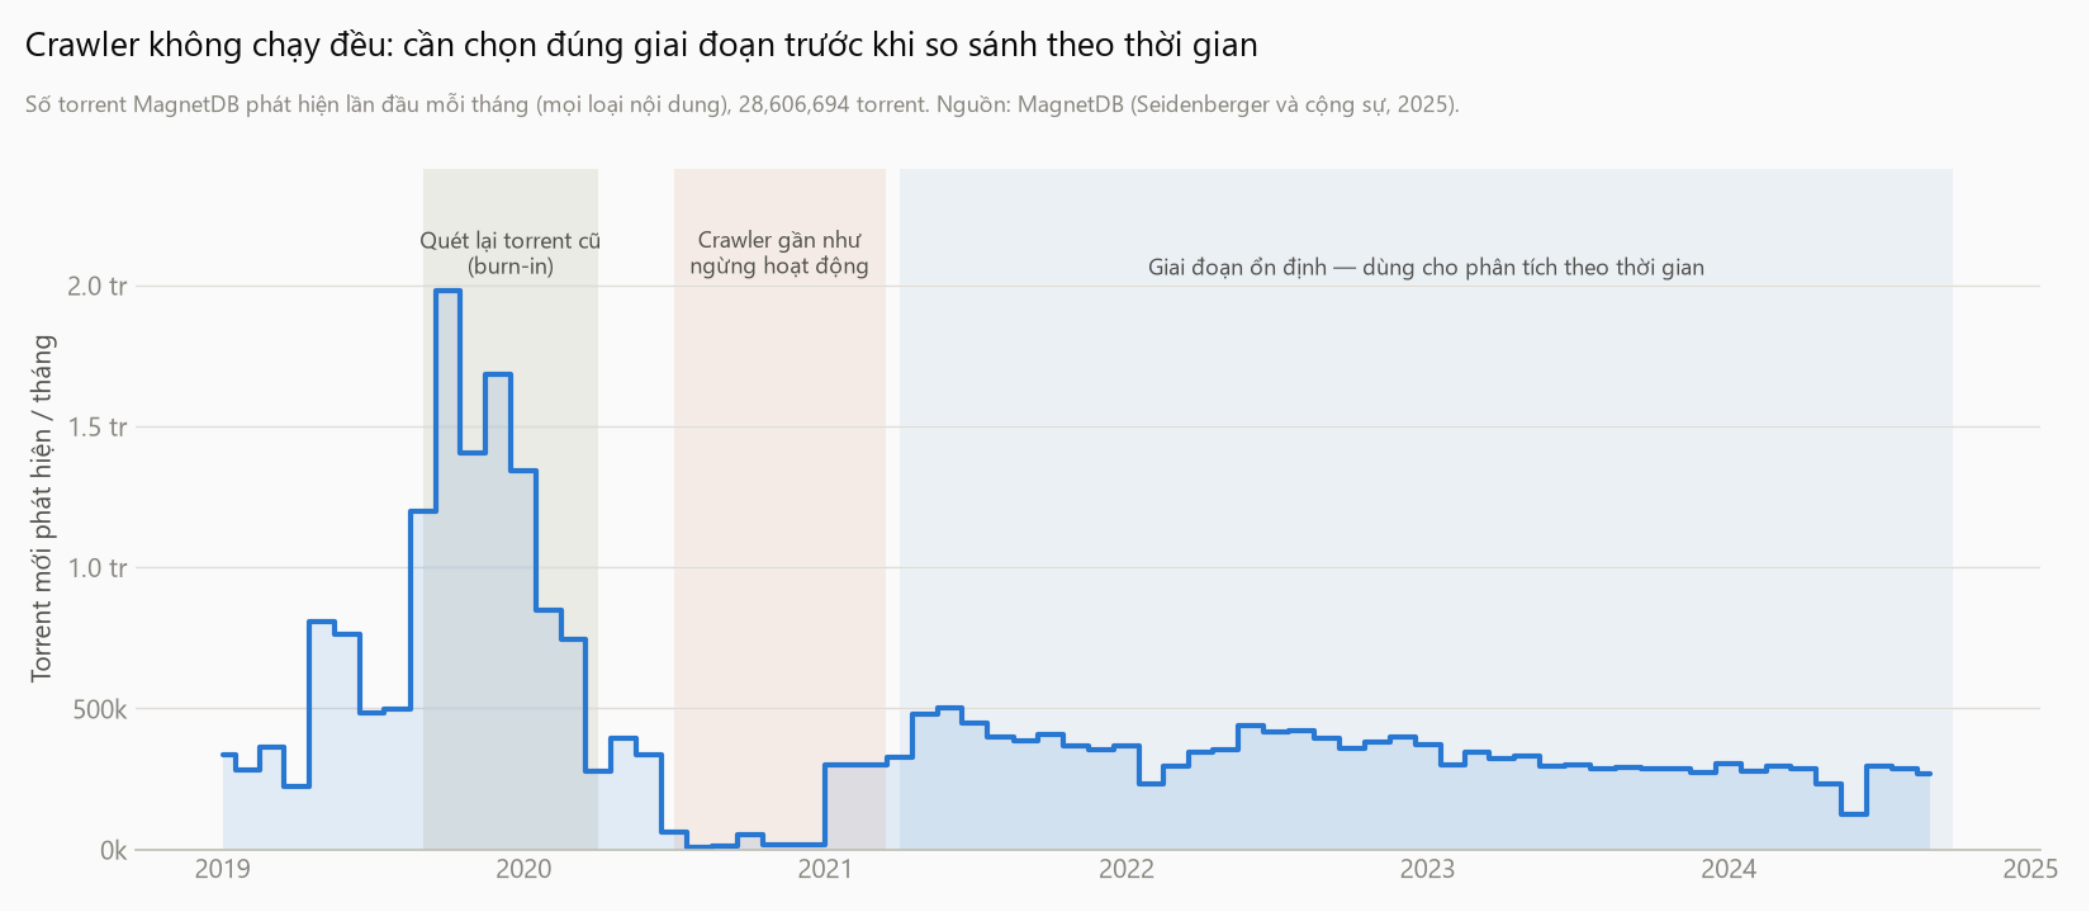
Trong kho chia sẻ có những loại nội dung nào?

Đếm theo file, mạng DHT đầy ảnh và nhạc; đo theo dung lượng, video chiếm gần 4/5

Vòng trong = nhóm nội dung; vòng ngoài = 3 định dạng lớn nhất mỗi nhóm (xám = các định dạng còn lại). Mẫu ngẫu nhiên 9,500,000 file (~1%) của bảng files. Nguồn: MagnetDB (Seidenberger và cộng sự, 2025).



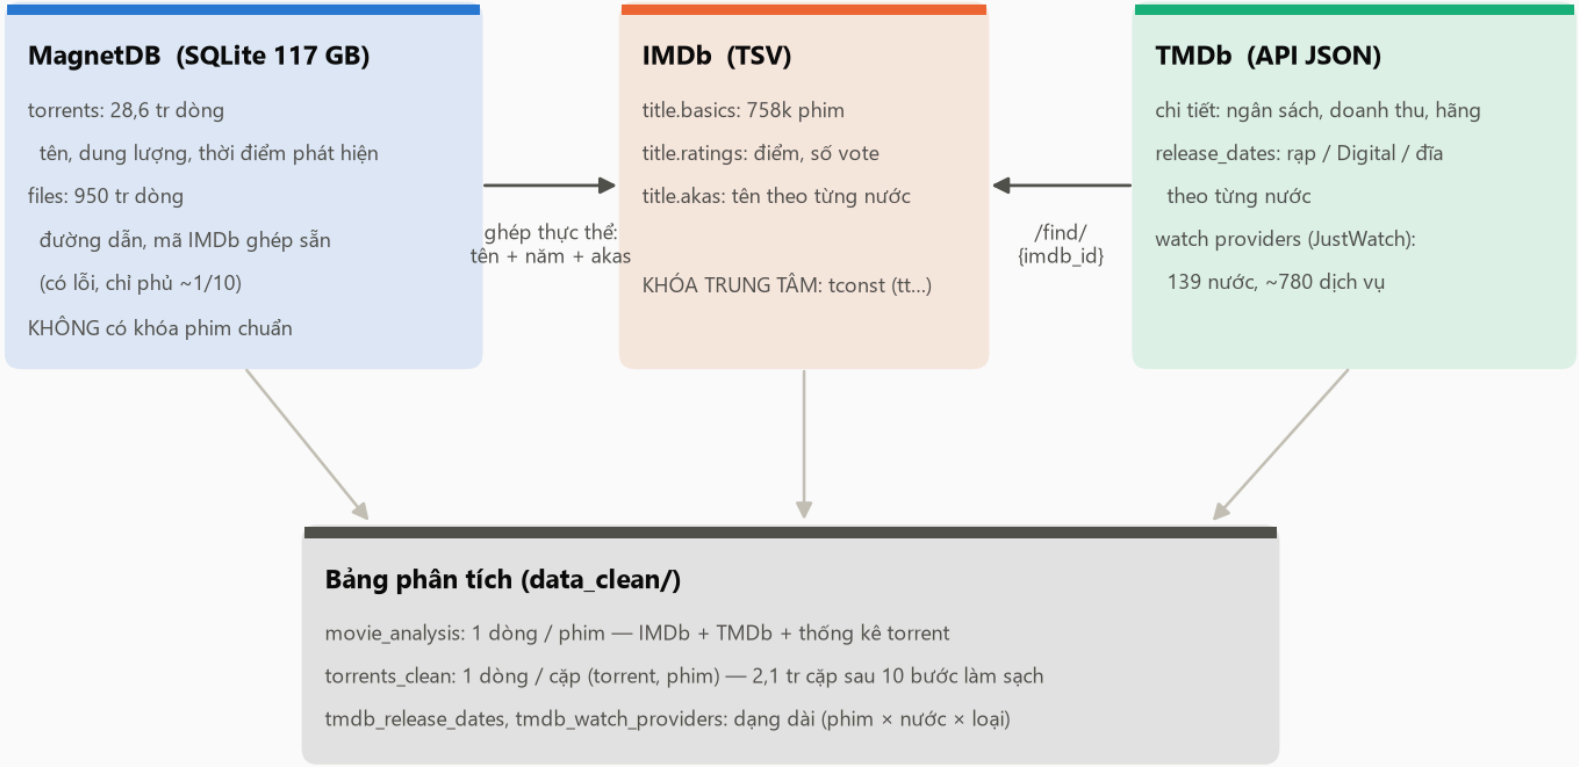
Chọn thời gian quan sát trước khi so sánh



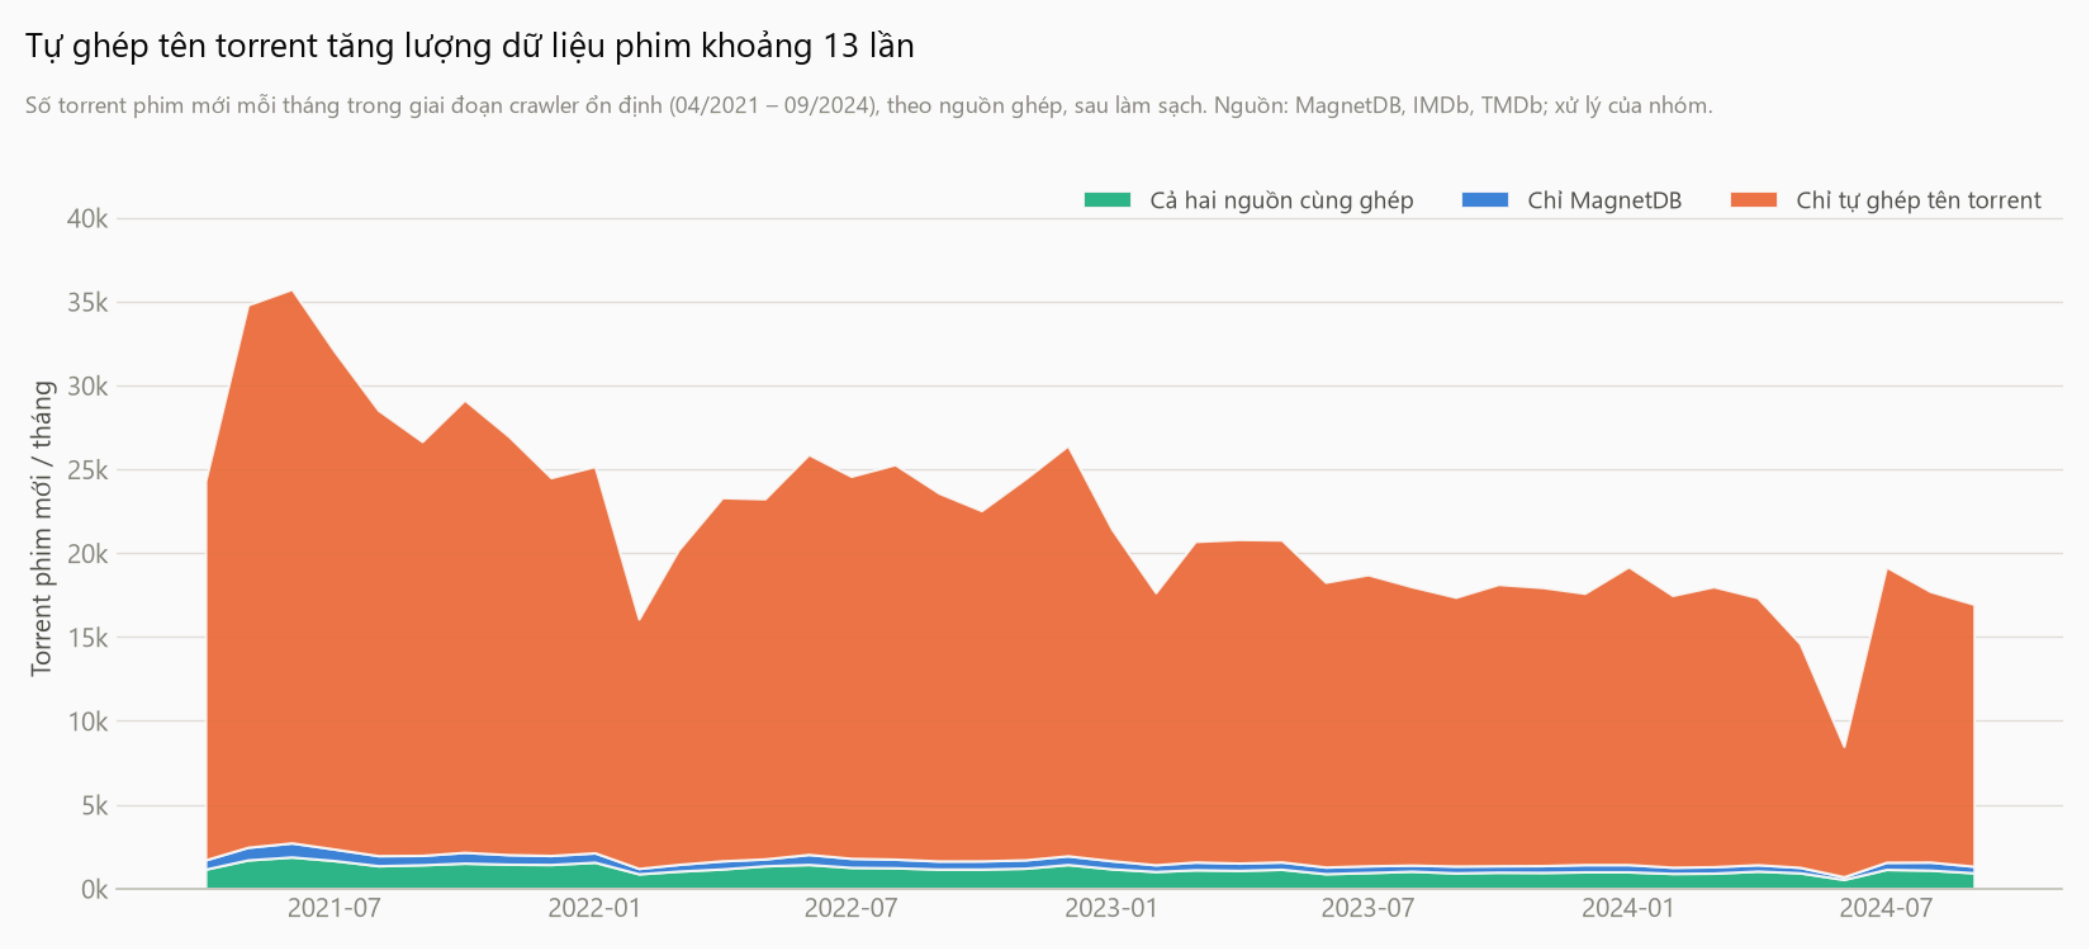
Nối ba nguồn về cùng một bộ phim

Ba nguồn, một khóa chung: mọi thứ nối với nhau qua mã phim IMDb

MagnetDB không có khóa phim chuẩn nên phải ghép thực thể từ tên file/torrent (chương 3); TMDb nối thẳng qua imdb_id.



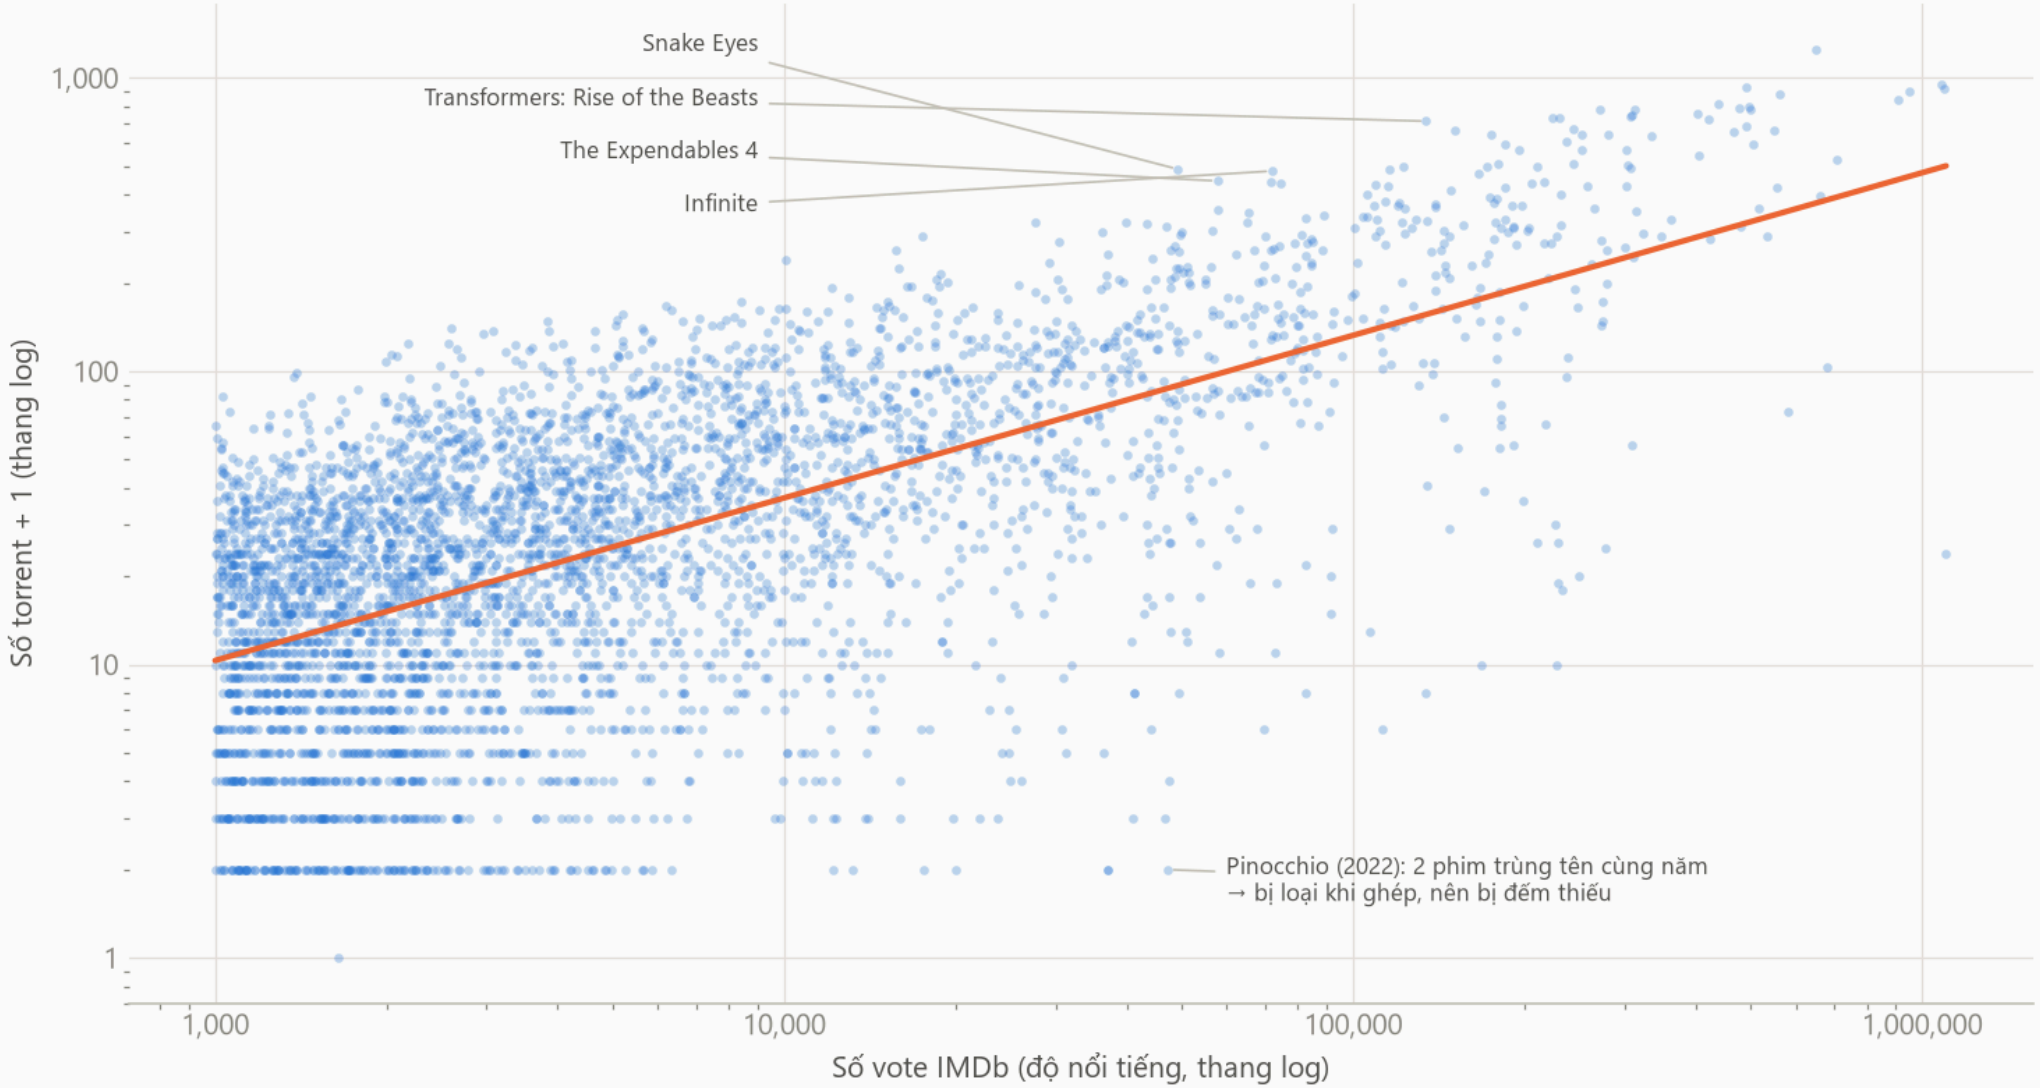
Tự ghép tên bổ sung độ phủ của dữ liệu



Sự quan tâm liên hệ thế nào với số bản chia sẻ?

Phim càng nổi tiếng càng bị chia sẻ lậu nhiều (R^2 = 0.39) — nhưng có những ngoại lệ thú vị

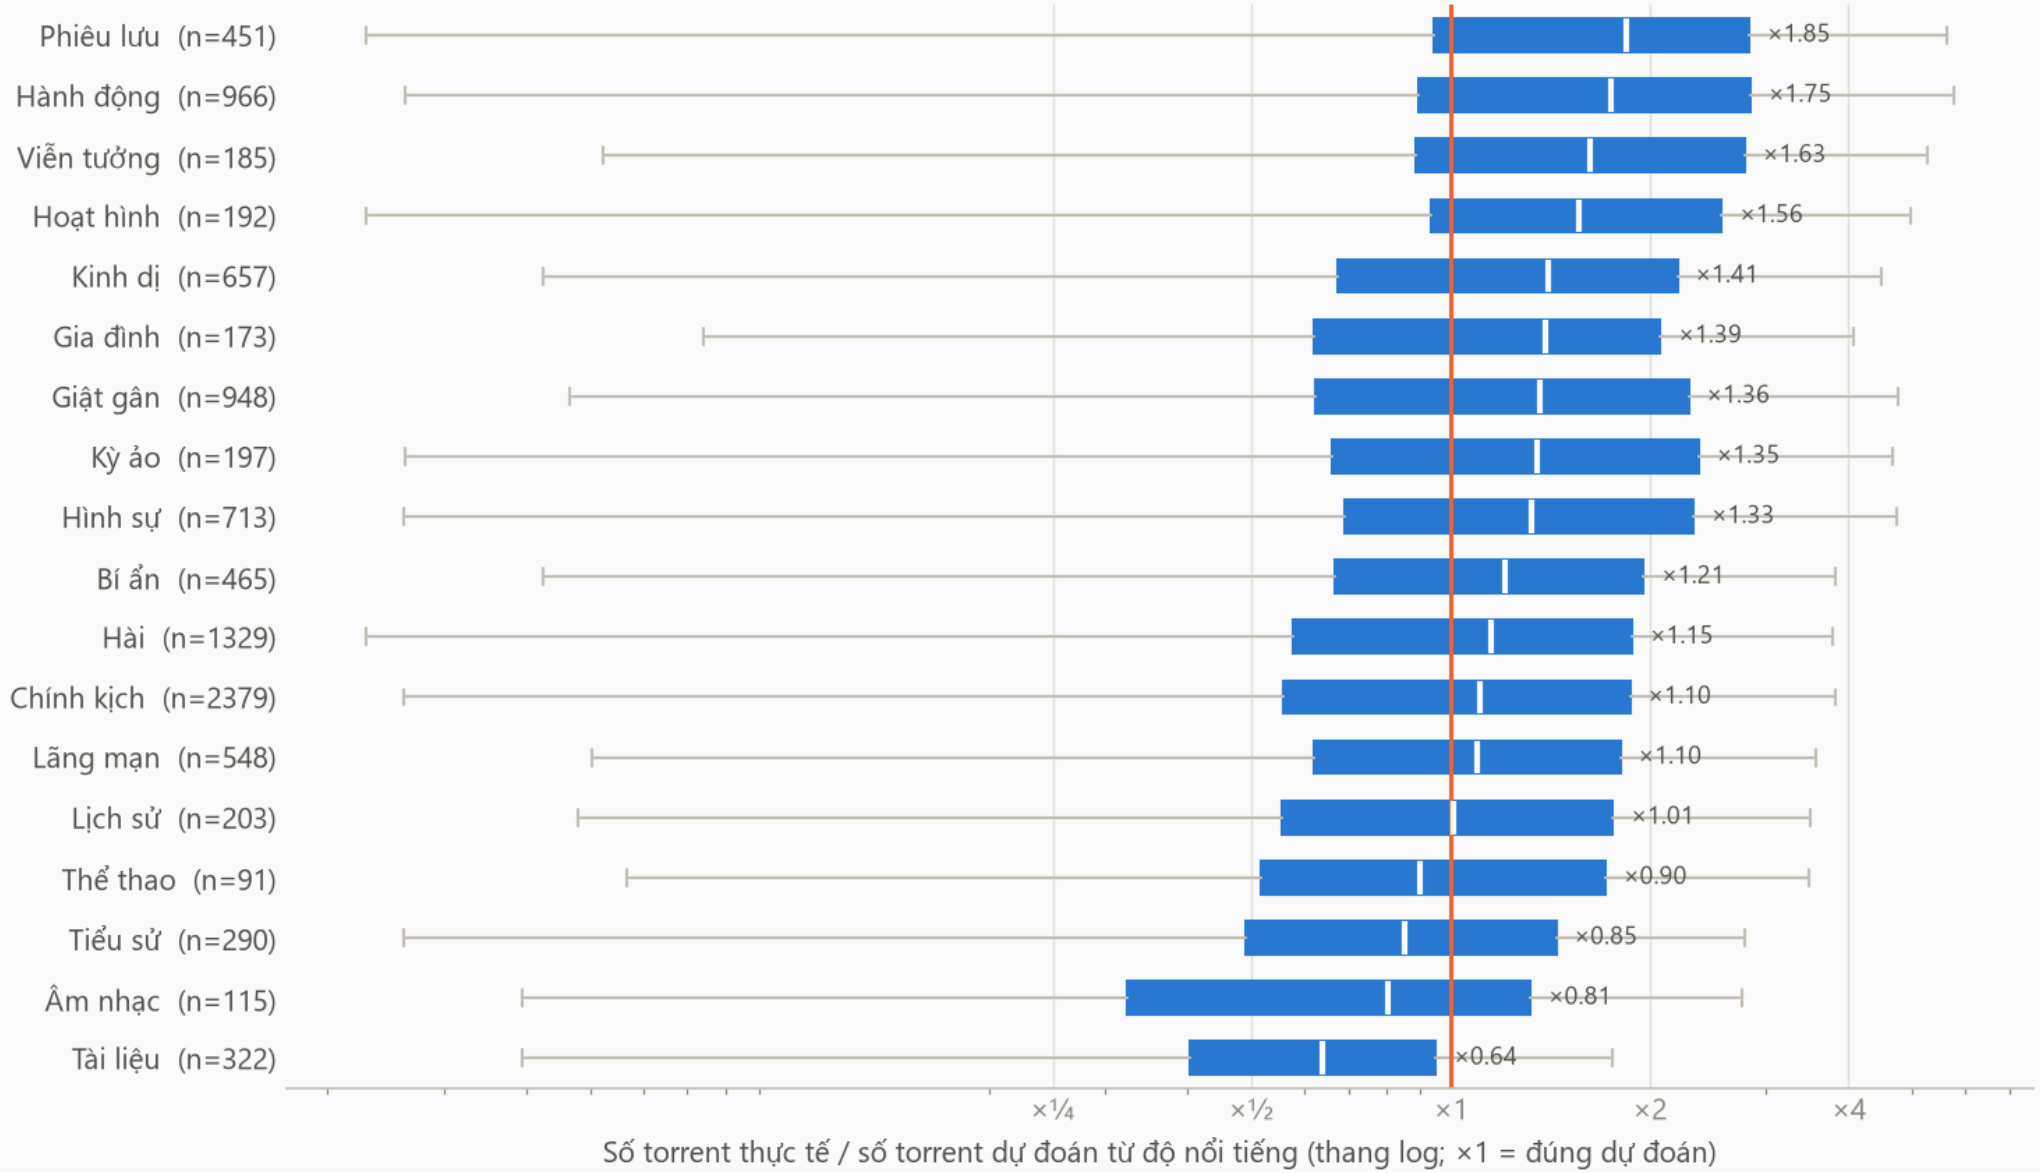
4,417 phim sản xuất 2021–2023 có ≥ 1.000 vote; đường cam = hồi quy log-log (hệ số 0.55: vote ×10 → torrent ×3.6). Bên trái đường: bị lậu nhiều hơn dự đoán; bên phải: ít hơn. Nguồn: MagnetDB, IMDb, TMDb; xử lý của nhóm.



Thể loại còn khác nhau sau khi xét sự quan tâm?

Phiêu lưu, hành động, viễn tưởng bị chia sẻ lậu nhiều hơn mức nổi tiếng; tài liệu, âm nhạc, tiểu sử ít hơn

Phần dư của hồi quy ở biểu đồ 2, theo thể loại (phim được tính ở mọi thể loại). Nguồn: MagnetDB, IMDb, TMDb; xử lý của nhóm.



Bản WEB được ghi nhận gần mốc Digital đến đâu?

Bản lậu chất lượng cao thường xuất hiện ngay khi phim ra bản online

962 phim ra rạp và online ở Mỹ 04/2021–09/2023 (≥ 1.000 vote IMDb); trung vị 0 ngày. Nguồn: MagnetDB, IMDb, TMDb; xử lý của nhóm.

